

11.2 国产云存储技术

► 11.2.1 淘宝分布式文件系统TFS

• 淘宝分布式文件系统TFS

Taobao File System (TFS) 是一个**高可扩展、高可用、高性能、面向互联网服务**的分布式文件系统，主要针对海量的非结构化数据，它构建在普通的Linux机器集群上，可对外提供**高可靠**和**高并发**的存储访问。

GFS中一个Chunk是__MB，一个文件被分为多个Chunk进行存储

淘宝提供海量小文件存储

通常文件大小不超过1MB，满足了淘宝对小文件存储的需求，被广泛地应用在淘宝各项应用中。

• 淘宝分布式文件系统TFS

Taobao File System (TFS) 是一个**高可扩展、高可用、高性能、面向互联网服务**的分布式文件系统，主要针对海量的非结构化数据，它构建在普通的Linux机器集群上，可对外提供**高可靠**和**高并发**的存储访问。

GFS中一个Chunk是64 MB，一个文件被分为多个Chunk进行存储

淘宝提供海量小文件存储

通常文件大小不超过1MB，满足了淘宝对小文件存储的需求，被广泛地应用在淘宝各项应用中。

• 淘宝分布式文件系统TFS

Taobao File System (TFS) 是一个**高可扩展、高可用、高性能、面向互联网服务**的分布式文件系统，主要针对海量的非结构化数据，它构建在普通的Linux机器集群上，可对外提供**高可靠**和**高并发**的存储访问。

淘宝提供海量小文件存储

采用了高容错架构和平滑扩容

保证了整个文件系统的可用性和扩展性。

• 淘宝分布式文件系统TFS

Taobao File System (TFS) 是一个**高可扩展、高可用、高性能、面向互联网服务**的分布式文件系统，主要针对海量的非结构化数据，它构建在普通的Linux机器集群上，可对外提供**高可靠**和**高并发**的存储访问。

淘宝提供海量小文件存储

采用了高容错架构和平滑扩容

扁平化的数据组织结构


可将文件名映射到文件的物理地址，简化了文件的访问流程，在一定程度上为TFS提供了良好的读/写性能。

11.2 国产云存储技术

1. 总体架构


- TFS主要由NameServer、DataServer和客户端组成。
- NameServer负责维护文件的元数据信息并管理DataServer。
- DataServer负责实际数据的存储。
- 客户端提供数据的存储访问，并向第三方应用提供数据访问接口。

□。




11.2 国产云存储技术

• 1. 总体架构





11.2 国产云存储技术

1. 总体架构



11.2 国产云存储技术

● 1. 总体架构



TFS主要针对海量**小文件**的存储，为了提高小文件的读/写性能，大量的小文件在内部都会**合并**为一个**大文件**，类似于GFS中Chunk。



定位Chunk的信息称为**一级索引**

Chunk内部的文件定位信息称为**二级索引**

TFS**文件名**中会包含这些索引信息，用户写入文件前，会向TFS**申请**TFS文件名，保证后续能够通过**解析**TFS文件名获取索引信息。

11.2 国产云存储技术

● 1. 总体架构



TFS命名方式 VS 传统文件系统POSIX接口


- 灵活性上不如传统文件系统POSIX接口
- 但扁平化的文件组织方式可以大大降低元数据的大小，保证NameServer可以支持PB级别的一级索引，系统可以获得更大的扩展性，
- 二级索引只需针对单台DataServer的数据量，这样就避免了因数据膨胀带来的索引膨胀。

11.2 国产云存储技术

• 2. 存储机制

在TFS中，用户的大量小文件在内部会合并为一个文件，这个大文件称为Block块。


- TFS以Block的方式组织文件的存储。
- 每一个Block在整个集群内拥有唯一的编号，这个编号由NameServer统一分配，但Block实际存储在DataServer上。
- NameServer需要维护所有Block信息列表，以及Block与DataServer之间的映射关系。



11.2 国产云存储技术


● 2. 存储机制

- 每个Block都会存储在多个DataServer节点上保证数据的冗余。
- 对于客户端发起的读/写请求，由NameServer选择合适的DataServer节点返回给客户端，
- 客户端直接与DataServer进行数据读/写操作。



11.2 国产云存储技术

- 2. 存储机制 NameServer需要维护Block信息列表，以及Block与DataServer之间的映射关系。存储的元数据结构如图所示。



11.2 国产云存储技术


• 2. 存储机制



- 一个DataServer节点上会有很多物理块，物理块以文件的形式存在磁盘上。
- DataServer会在部署前预先分配好物理块，以保证后续的访问速度和减少碎片的产生。
- 为了满足这个特性，DataServer一般在EXT4文件系统上运行。

11.2 国产云存储技术

• 2. 存储机制



- 物理块分为主块和扩展块。
- 一般主块远大于扩展块
- 使用扩展块是为了满足文件更新操作时文件大小的变化。
- 每个Block在文件系统上以“主块+扩展块”的方式存储。
- 每一个Block可能对应于多个物理块，其中包括一个主块，多个扩展块。

11.2 国产云存储技术

● 3. 容错机制

1) 集群容错

GFS没有集群容错机制

2) NameServer容错

3) DataServer容错

11.2 国产云存储技术

● 3. 容错机制

1) 集群容错

- TFS可以配置**主辅集群**，一般主辅集群会存放在两个**不同**的机房。
- **主集群**提供所有功能，**辅集群**只提供读。
- 主集群会把所有操作**重放**到辅集群，这样既提供了**负载均衡**，又可以在主集群机房出现异常情况时，不会中断服务或丢失数据。

11.2 国产云存储技术

● 3. 容错机制

1) 集群容错

2) NameServer容错

- NameServer采用HA结构主备模式，一主一备，主NameServer上的操作会重放到备NameServer。如果主NameServer出现问题，可以实时切换到备NameServer。
- NameServer和DataServer之间也会有定时的heartbeat，DataServer会把自己拥有的Block发送给NameServer。当DataServer发生故障时，NameServer会根据这些信息重建DataServer和Block的关系。

2.1 Google文件系统GFS

• Master容错

Master

命名空间 (Name Space) , 也就是整个文件系统的目录结构。

Chunk与文件名的映射表。

Chunk副本的位置信息, 每一个Chunk默认有三个副本。

GFS通过**操作日志**来提供容错功能

直接保存在各个**Chunk Server**上

当Master发生故障时, 在**磁盘**数据保存完好的情况下, 可以迅速恢复以上元数据

为了防止Master彻底死机的情况, GFS还提供了Master**远程的实时备份**

11.2 国产云存储技术

● 3. 容错机制

1) 集群容错

2) NameServer容错

3) DataServer容错

- TFS采用Block存储多份的方式来实现DataServer的容错，一般为3份，并且分布在不同网段的不同DataServer上。
- 对于每一个写入请求，必须在所有的Block写入成功时才算成功。
- 当出现磁盘损坏DataServer宕机时，TFS启动复制流程，把备份数未达到最小备份数的Block尽快复制到其他DataServer上。
- TFS对每一个文件会记录校验CRC（循环冗余码），当客户发现CRC和文件内容不匹配时，会自动切换到一个好的Block上读取。此后，客户端将会实现自动修复单个文件损坏的情况。

2.1 Google文件系统GFS

● Chunk Server容错

GFS采用副本的方式实现Chunk Server的容错

每一个Chunk有多个存储副本（默认为三个），在不同的Chunk Server上

对于每一个Chunk，必须将所有的副本全部写入成功，才视为成功写入

相关的副本出现丢失或不可恢复等情况，Master自动将该副本复制到其他Chunk Server

GFS中的每一个文件被划分成多个Chunk，Chunk的默认大小是64MB

每一个Chunk以Block为单位进行划分，大小为64KB，每一个Block对应一个32bit的校验和

● 4. 平滑扩容



- **TFS集群容量不足时**，只需新增DataServer，在上面部署好应用程序后**启动即可**。这些DataServer会向NameServer进行**心跳汇报**。用户写入数据时，NameServer会根据DataServer**容量**的比率和**负载情况**选择合适的DataServer节点进行数据存储。
- **在集群负载较轻时**，NameServer会对DataServer上的Block进行**均衡**，保证每个DataServer的Block数尽可能均衡。进行均衡计划时，首先计算每台DataServer上拥有的Block**平均数量**，然后将DataServer划分为两堆，一堆**超过**平均数量的，作为**移动源**，一堆**低于**平均数量的，作为**移动目的**。



查阅资料：

了解最先进的分布式文件系统。

The background of the image is a dark gray field filled with a complex network of thin, light gray lines. These lines connect numerous circular nodes of varying sizes, creating a web-like or molecular structure. The nodes are also light gray, and some are larger than others, adding depth to the pattern.

本章未完待续