

只是题型示例，不是题库！
下面列出的是重要的知识点，考试的时候可能考的形式会变化，不一定能遇到原题。

主观题示例

题干：云计算与大数据的关系是什么？

答案： $G=f(x)$ ， x 是大数据， f 是云计算， G 是目标。云计算是处理大数据的手段，大数据与云计算是一枚硬币的正反面。大数据是需求，云计算是手段。没有大数据，就不需要云计算。没有云计算，就无法处理大数据。

题干：云计算的 7 个特点是什么？

答案：超大规模、虚拟化、高可靠性、通用性、高可伸缩性、按需服务、极其廉价。

题干：云计算的服务类型有哪些？请对每个服务类型进行说明。

答案：云计算的服务分类三大类：SaaS、PaaS、IaaS。SaaS 是指将软件作为服务，它将某些特定应用软件功能封装成服务。PaaS 是将平台作为服务，提供用户应用程序的运行环境，负责资源的动态扩展和容错管理，用户应用程序不必过多考虑节点间的配合问题。IaaS 是将基础设施作为服务，它将硬件设备等基础资源封装成服务供用户使用，用户相当于在使用裸机和磁盘。

题干：云计算有长、短两种定义，其长定义是什么？

答案：云计算是一种商业计算模型。它将计算任务分布在大量计算机构成的资源池上，使各种应用系统能够根据需要获取计算力、存储空间和信息服务。

题干：云计算有长、短两种定义，其短定义是什么？

答案：云计算是通过网络按需提供可动态伸缩的廉价计算服务。

题干：大数据的 4V+1C 的特征具体是什么？

答案：快速、价值密度低、数据量大、多样、复杂度。

题干：大数据的定义是什么？

答案：海量数据或巨量数据，其规模巨大到无法通过目前主流的计算机系统在合理时间内获取、存储、管理、处理并提炼以帮助使用者决策。

题干：为什么全球数据量增长如此之快？

答案：(1) 数据产生方式的改变：数据的产生方式从手工产生变得越来越自动化；对环境的感知，是一种抽样的手段，抽样密度越高，越逼近真实情形；为了收集全量信息，传感器的使用量暴增，导致了信息爆炸；(2) 人类的活动越来越依赖数据：人类的日常生活已经与数据密不可分；科学研究进入了“数据科学”时代；各行各业也越来越依赖大数据手段来开展工作。

题干：在性价比上云计算相比传统技术为什么有压倒性的优势？

答案：主要原因在于它的技术特征和规模效应所带来的压倒性的性能价格比优势。

题干：Google 的文件系统除了软硬件的支持, 还需要哪些系统管理技术的支持?

答案：大规模集群安装技术、故障检测技术、节点动态加入技术和节能技术。

题干：Google 云计算技术包括哪些?

答案：Google 文件系统 GFS、分布式计算编程模型 MapReduce、分布式锁服务 Dapper、海量数据的交互式分析工具 Dremel, 以及内存大数据分析系统 PowerDrill 等。

题干：Google 的文件系统中的 Master 上, 保存的三种元数据是什么?

答案：命名空间、Chunk 与文件名的映射表, 以及 Chunk 副本的位置信息。

题干：MapReduce 封装了什么?

答案：MapReduce 封装了并行处理、容错处理、本地化计算、负载均衡等细节, 还提供了一个简单而强大的接口。

题干：Google 的分布式锁服务中有哪 3 种类型的节点? 其作用分别是什么?

答案：Chubby 中有 proposers、acceptors 和 learners。Proposers 提出决议, acceptors 批准决议, learners 获取并使用已经通过的决议。

题干：Chubby 系统规定每个节点的元数据都应当包含哪四种单调递增的编号? 它们分别在什么时候递增?

答案：(1) 实例号：新节点生成时递增；(2) 内容生成号：文件内容修改时递增；(3) 锁生成号：锁被用户持有时递增；(4) ACL 生成号：ACL 名被覆盖时递增。


题干：Paxos 算法的三个主要条件是什么?

答案：(1) 决议只有在被 Proposers 提出后才能被批准；(2) 每次只批准一个决议；(3) 只有决议确定被批准后 Learners 才能获取这个决议。

题干：Bigtable 中有哪 3 种压缩方式? 是怎样进行的?

答案：Bigtable 中有次压缩、合并压缩和主压缩三种压缩方式。Bigtable 中每次旧的内存表停止使用时都会执行一次次压缩操作, 产生一个 SSTable。Bigtable 会定期执行一次合并压缩操作, 将一些已有的 SSTable 和现有的内存表一并进行一次压缩。Bigtable 中的主压缩其实是合并压缩的一种, 将所有 SSTable 一次性压缩成一个大的 SSTable 文件, 该操作也是定期执行一次。一次主压缩之后, 所有被压缩数据会被彻底删除, 既回收了空间又能保证敏感数据的安全性。

题干：如图所示, 子表地址的查询采用的是一种类似 B+树的三层查询体系, 请简述其查询过程。



答案：首先，从 Chubby 中提取根子表的地址；进而，读取所需的元数据子表的位置；最后，从元数据子表中找到待查询的用户表地址。

题干：为了减少开销、提高客户访问效率，Bigtable 使用了哪两种技术？其含义分别是什么？

答案：Bigtable 采用了缓存和预存取技术。缓存是指子表的地址信息被缓存在客户端，客户寻址时直接根据缓存信息进行查找。预存取是指在每次访问元数据表时，不仅仅读取所需的子表元数据，而是读取多个子表的元数据，这样下次需要时，就不用再次访问元数据表了。


题干：Bigtable 的局部性群组是指什么？

答案：Bigtable 允许用户将原本并不存储在一起的数据以列族为单位，根据需要组织在一个单独的 SSTable 中，以构成一个局部性群组。


题干：Dapper 的二次抽样技术的具体方法是什么？好处是什么？

答案：在数据写入 Bigtable 前，Dapper 将监控 id 散列成一个标量 z ，如果某个区间的 z 小于事先定义好的汇总抽样系数，则保留这个区间并将它写入 Bigtable，否则丢弃。其好处是，只需改动 z 值就可以改变整个系统的写入数据量，解决了低开销及广泛可部署性的问题。

题干：请根据以下注释内容画出监控树。(画出的监控树区间中需要写明注释信息。)



答案：



题干：Dapper 监控信息的汇总需要哪个步骤？

答案：(1) 将区间的数据写入到本地的日志文件中。(2) 利用 Dapper 守护进程和 Dapper 收集器将所有机器上的本地日志文件汇集到一起。(3) 将汇集后的数据写入到 Bigtable 存储库中。

题干：Dapper 适合在哪些场景中使用？请列举 2 个。

答案：在新服务的部署时，定位长尾延迟时，或在推断服务间的依存关系时，确定不同服务的网络使用情况时，在分层的共享式存储系统中，“火拼”时。

题干：在嵌套式的列存储中，重复深度和定义深度的含义是什么？

答案：重复深度记录的是该列的值是在哪个级别上重复的。定义深度表示“值的路径中有多少可以不被定义（可重复类型或可选类型）的字段实际是有意义的”。

题干：PowerDrill 中组合范围分区的大致方法是什么？

答案：大致方法是由领域专家确定若干个划分的域，然后依次利用这几个域对数据进行划分；设定阈值，当每个块的行数达到这个阈值时，就停止划分。

题干：PowerDrill 和 Dremel 的设计目标和设计理念都不同，其设计目标有哪些不同？

答案：Dremel 用来处理非常大的数据集，而 PowerDrill 用来分析少量的核心数据集。

题干：PowerDrill 和 Dremel 的设计目标和设计理念都不同，其设计理念有哪些


不同？

答案：(1) Dremel 处理的数据来自外存，PowerDrill 处理的数据来自内存。(2) Dremel 未进行数据分析，分析时要扫描所有的列；PowerDrill 使用了组合范围分区，分析时可以跳过很多不需要的分区。(3) Dremel 数据通常不需要加载，增加数据很方便；PowerDrill 数据需要加载，加载数据相对不便。

题干：AWS 提供的服务主要包括哪些？请列举 3 个。

答案：弹性计算云 EC2、简单存储服务 S3、简单数据库服务 SimpleDB，或简单队列服务 SQS、弹性 MapReduce 服务、内容推送服务 CloudFront、电子商务服务 DevPay 和灵活支付服务 FPS 等。

题干：Dynamo 的向量时钟原理图如下，请补充向量时钟的具体内容。



答案：D1([Sx, 1]), D2([Sx, 1], [Sy, 1]), D3([Sx, 2], [Sy, 1]), D4([Sx, 1], [Sy, 1], [Sz, 1]), D5([Sx, 3], [Sy, 1], [Sz, 1])

选择题示例

题干：在云计算的体系结构中，^{SOA层}封装云计算能力成标准的 Web Services 服务应属于 ()。

- A、SOA 构建层
- B、资源池层
- C、管理中间件层
- D、物理资源层

题干：研究在一个标准集装箱的空间如何装下 2000 个服务器、解决散热和故障节点替换的问题并降低能耗，这属于云计算技术体系中 () 需要考虑的问题。

- A、SOA 构建层
- B、资源池层
- C、管理中间件层
- D、物理资源层

题干：云计算的 7 个特点中不包括（ ）。

- A、超大规模
- B、极其昂贵
- C、虚拟化
- D、高可靠性

题干：Google 的文件系统将整个系统的节点分为三类角色，包括（ ）、Master（主服务器）和 Chunk Server（数据块服务器）。

- A、Cloud（云端）
- B、Edge Server（边缘服务器）
- C、Client（客户端）
- D、以上都不是

题干：Google 的文件系统采用中心服务器模式，其缺点是（ ）。

- A、Master 无法增加 Chunk Server
- B、Master 无法进行负载均衡
- C、Master 无法保证元数据的一致性
- D、Master 极易成为整个系统的瓶颈

题干：Google 的文件系统的优点不包括（ ）。

- A、采用中心服务器模式
- B、不提供专用接口
- C、无需缓存数据
- D、在用户态下实现

题干：Google 的文件系统采用（ ）的方式实现 Chunk Server 的容错。

- A、副本
- B、缓存
- C、故障检测
- D、并行计算

题干：Google 的文件系统采用（ ）的方式实现 Master 的容错。

- A、实时远程备份
- B、缓存
- C、故障检测
- D、并行计算

题干：MapReduce 封装了（ ）、容错处理、本地化计算、负载均衡等细节，还提供了一个简单而强大的接口。

- A、并行处理
- B、串行处理
- C、远程计算
- D、过程监控

题干：MapReduce 可能存在 Master 失效和 Worker 失效两种情况，而由于只有一个 Master 在运行，所以，如果 Master 失效了，则（ ）。

- A、切换到另一个 Master 上继续运行
- B、只能终止整个 MapReduce 程序的运行并重新开始
- C、选举一个 Worker 继续运行
- D、以上都不对

题干：（ ）是为 Google 提供了粗粒度锁服务的文件系统，它基于松耦合分布式系统，解决了分布的一致性问题。

- A、MapReduce
- B、Chubby
- C、Hadoop
- D、Dremel

题干：Google 文件系统的锁服务采用的是（ ）的锁服务，它是基于（ ）的分布式系统，解决了分布的一致性问题。

- A、粗粒度、松耦合
- B、细粒度、松耦合
- C、粗粒度、紧耦合
- D、粗粒度、紧耦合

题干：Google 文件系统的锁服务不能解决的问题是（ ）。

- A、分布的一致性
- B、选取主服务器
- C、内部的名字服务
- D、关键节点延迟的监控

题干：Google 的分布式锁服务中有 3 种节点，其中，提出决议的节点是（ ）。

- A、Acceptors
- B、Proposers
- C、Learners
- D、Workers

题干：Google 的分布式锁服务中单调递增的是：（ ）、内容生成号、锁生成号和 ACL 生成号。

- A、实例号
- B、延迟
- C、名字
- D、元数据

题干：Google 的分布式锁服务的客户端的危险状态临界点位于（ ）的边界。

- A、租约期到宽限期
- B、宽限期到租约期
- C、租约期到租约期
- D、宽限期到宽限期


题干：Google 的分布式锁服务的客户端的安全状态临界点位于（ ）的边界。

- A、租约期到宽限期
- B、宽限期到租约期
- C、租约期到租约期
- D、宽限期到宽限期

题干：Bigtable 是一个分布式多维映射表，表中的数据通过一个行关键字、一个（ ）以及一个时间戳进行索引。

- A、用户账号
- B、序号
- C、列关键字
- D、指针

题干：如图所示，Bigtable 中一次旧的内存表停止使用时，都会进行一个（ ）操作，这会产生一个 SSTable。



- A、初步压缩
- B、次压缩
- C、主压缩
- D、合并压缩

题干：Megastore 提供了三种方式的读，分别是（ ）、snapshot 和 inconsistent。

- A、click
- B、read
- C、photo
- D、current





题干：Megastore 的基本架构中，最底层的数据是存储在（ ）中的。

- A、函数库
- B、复制服务器
- C、Bigtable
- D、Dapper

题干：Megastore 中，（ ）用于在 Paxos 算法执行过程中无法产生一个决议时参与投票，只存储日志而不存储具体数据。

- A、完整副本
- B、见证者副本
- C、只读副本
- D、协调者

题干：Megastore 中，如图所示，第（ ）行的数据是具有完全一致性的。

	副本A	副本B	副本C
99			
100			
101			
102			
103			
104			

- A、99
- B、101
- C、102
- D、103

题干：Dapper 的监控树中的每个节点就是一个（ ），实际上就是一条记录，所有记录联系起来就是对某个事件的完整记录。

- A、记事本
- B、服务器
- C、区间
- D、用户

题干：在监控系统 Dapper 中，（ ）主要用来辅助推断区间关系，也可以包含一些自定义的内容。

- A、内存表
- B、限定词
- C、注释
- D、族名

题干：在监控系统 Dapper 中，通过（ ）才能对监控树中不同区间的关系进行重建。

- A、区间名
- B、区间 id
- C、监控 id
- D、父 id

题干：在监控系统 Dapper 中，（ ）在整个系统中是唯一的，且对于同一棵监控树中所有区间来说是相同的。

- A、区间名

- B、区间 id
- C、监控 id
- D、父 id

题干：适合对本地磁盘上的海量数据进行实时的数据交互和数据探索的技术是（ ）。

- A、MapReduce
- B、Dremel
- C、PowerDrill
- D、Dapper

题干：Dremel 采用的数据存储方式是（ ）。

- A、行存储
- B、列存储
- C、嵌套式的列存储
- D、面向记录的存储

题干：PowerDrill 采用的压缩算法是（ ）。

- A、GZIP
- B、RAR
- C、Zippy
- D、LZO

题干：PowerDrill 采用的分区方法是（ ）。

- A、磁盘分区
- B、散列分区
- C、范围分区
- D、组合范围分区

题干：PowerDrill 系统开发和优化的基础假设是（ ）。

- A、绝大多数的查询是类似和一致的
- B、存储系统中的表只有一小部分是经常被使用的
- C、存储系统中绝大部分的表使用频率不高
- D、以上都是

题干：为了实现高效的查询，PowerDrill 开发团队主要考虑的内容是（ ）。

- A、如何尽可能在查询中略去不需要的数据分块
- B、如何尽可能地减少数据在内存中的占用
- C、如何尽可能地将更多的数据加载进内存中处理
- D、以上都是

题干：PowerDrill 的数据结构采用的是（ ）。

- A、双层数据字典
- B、链表
- C、队列

D、栈

题干：PowerDrill 整个系统实际分为三个部分：WebUI、一个抽象层和（ ）。

- A、数据链路层
- B、图像层
- C、行存储
- D、列式存储

题干：游程编码是常用的数据压缩算法，BBCCCLLLL 的编码结果是（ ）。

- A、[B, 2, 1][C, 3, 3][L, 4, 6]
- B、[B, 1, 2][C, 3, 3][L, 6, 4]
- C、[B, 1, 2][C, 2, 3][L, 3, 4]
- D、[B, C, L][1, 2, 3][2, 3, 4]

题干：Google APP Engine 可以提供图像操作 API、邮件 API、Memcache API、（ ）和数据库 API。

- A、付款 API
- B、用户 API
- C、导航 API
- D、服务器 API

题干：Google APP Engine 的架构分为四部分，其中，负责将请求转发给应用服务器，并进行负载均衡和静态文件的传输的部分是（ ）。

- A、前端和静态文件
- B、应用服务器
- C、服务器群
- D、应用管理节点

题干：Google APP Engine 的架构分为四部分，其中，能同时运行多个应用的运行时的部分是（ ）。

- A、前端和静态文件
- B、应用服务器
- C、服务器群
- D、应用管理节点

题干：Google APP Engine 的架构分为四部分，其中，能提供如 Memcache、Images、URLfetch、E-mail 和 Data Store 等服务的部分是（ ）。

- A、前端和静态文件
- B、应用服务器
- C、服务器群
- D、应用管理节点

题型：单选题 易

题干：Google APP Engine 的架构分为四部分，其中，负责应用的启停和计费的部分是（ ）。

- A、前端和静态文件
- B、应用服务器
- C、服务器群
- D、应用管理节点


题干：Dynamo 采用（ ）解决数据均衡分布问题。

- A、参数可调的弱 quorum 机制
- B、改进的一致性哈希算法
- C、向量时钟
- D、Merkle 哈希树

题干：Dynamo 采用（ ）解决数据备份问题。


- A、参数可调的弱 quorum 机制
- B、改进的一致性哈希算法
- C、向量时钟
- D、Merkle 哈希树

题干：在一致性哈希算法中，数据对象和服务器的位置如下图所示，对象 1 应该存储在（ ）。



- A、节点 1
- B、节点 2
- C、节点 3
- D、节点 4


题干：在改进的一致性哈希算法中，哈希环与节点对照表如下所示，对象 1 应该存储在（ ）。



物理节点	虚拟节点
1	1、2
2	3、4
3	5、6、7
4	8


- A、物理节点 1
- B、物理节点 2
- C、物理节点 3
- D、物理节点 4

题干：在改进的一致性哈希算法中，哈希环如下所示。当虚拟节点 6 和虚拟节点 8 之间新增了虚拟节点 7 时，（ ）需要进行数据迁移。



- A、对象 1
- B、对象 2
- C、对象 3
- D、对象 4

题干：在改进的一致性哈希算法中，哈希环与节点对照表如下所示。当虚拟节点 6 和虚拟节点 8 之间新增了虚拟节点 7 时，对象 3 会存储在（ ）上。



物理节点	虚拟节点
1	1、2
2	3、4
3	5、6、7
4	8

- A、物理节点 1
- B、物理节点 2
- C、物理节点 3
- D、物理节点 4

题干：Dynamo 中数据的备份存储在哈希环的（ ）。

- A、顺时针方向上的后继节点中
- B、逆时针方向上的前驱节点中
- C、随机选择的节点中
- D、顺时针间隔 2 个节点的后继节点中


题干：依据 Dynamo 的弱 quorum 机制，当副本数 $N=3$ 时，设置（ ）可以使得读效率较高，写可靠性较高。

- A、 $R=3, W=3$
- B、 $R=3, W=1$
- C、 $R=1, W=3$
- D、 $R=1, W=1$

题干：依据 Dynamo 的 Gossip 协议，假如一个新节点加入了一个节点总数为 10 的系统，并以最优的方式进行传播，将新节点信息传遍整个系统需要的时间复杂度为（ ）。


- A、 $\log 2$
- B、 $\log 10$
- C、 $\log 2 \times 10$
- D、 $\log 10 \times 10$

题干：哈希环如下所示，在 Dynamo 的容错机制中，假设数据副本数量为 3, 对象 1 应该存储在（ ）上。




- A、虚拟节点 1、虚拟节点 2、虚拟节点 3
- B、虚拟节点 2、虚拟节点 3、虚拟节点 4
- C、虚拟节点 3、虚拟节点 4、虚拟节点 5
- D、虚拟节点 1、虚拟节点 8、虚拟节点 7

题干：哈希环如下所示，在 Dynamo 的容错机制中，假设数据副本数量为 3，虚拟节点 4 上应该存储的数据包括（ ）。




- A、对象 3、对象 4
- B、对象 2、对象 3、对象 4、对象 5
- C、对象 1、对象 2、对象 3、对象 4
- D、对象 1、对象 2、对象 3、对象 4、对象 5

题干：哈希环如下所示，在 Dynamo 的容错机制中，假设数据副本数量为 3，节点 1 发生了临时故障，则需要记入节点 1 的数据会写入（ ）的临时空间中。



- A、节点 2
- B、节点 3
- C、节点 4
- D、节点 5

题干：Dynamo 在数据传输时，计算出的 Merkle 树如下图所示，（ ）发生了错误。



- A、文件 1
- B、文件 3
- C、文件 5
- D、文件 7

判断题示例

题干：云计算将计算变成了大众用得上和用得起的“水和电”。

答案：对

题干：云计算平台的规模极大，很难平稳整体负载。

答案：错

题干：云计算的资源利用率可以达到 80%左右，是传统模式 5~7 倍。

答案：对

题干：数据中心通常建在人烟稀少、气候寒冷、水电资源丰富的地区。

答案：对

题干：云计算与传统互联网数据中心 (IDC) 相比，IDC 为用户提供的网络带宽、处理能力和存储空间都是固定的。

答案：对

题干：Google 的文件系统采用的是 TFS。

答案：错

题干：Google 的文件系统中，在 Client 与 Master 之间需要同时传输控制流和数据流。

答案：错

题干：Google 的文件系统中，文件只能被逐个访问，不能同时访问多个文件，这样可以保障系统的可靠性。

答案：错

题干：Google 的文件系统中，Client 可以同时访问多个 Chunk Server，从而使得整个系统的 I/O 高度并行。

答案：对

题干：MapReduce 中，Reduce 对原始数据进行缩减得到中间结果，而对中间结果继续进行归并映射的是 Map 操作。

答案：错

题干：Google 文件系统的锁服务解决了分布的一致性问题。

答案：对

题干：Google 文件系统的锁服务是一种建议性的锁，使系统具有更大的灵活性。

答案：对

题干：Google 文件系统的锁服务基于 Paxos 算法。

答案：对

题干：Google 文件系统的锁服务可以作为一个稳定的存储系统存储包括元数据在内的小数据。

答案：对

题干：Google 文件系统的锁服务可以为内部提供名字服务。

答案：对

题干：Google 文件系统使用 Chubby 选取主服务器。

答案：对

题干：Paxos 算法中只能有 1 个 Proposer，但可以有多个 Acceptor。

答案：错

题干：Paxos 算法中的一个节点可以兼有多重类型。

答案：对

题干：在 Google 的分布式锁服务中，每次可以批准多个决议。

答案：错

题干：Google 的分布式锁服务批准某个决议的核心思想是“少数服从多数”。

答案：对

题干：Google 的分布式锁服务的五个副本服务器单元在配置上完全一致，且在系统刚开始时处于对等地位。

答案：对

题干：在 Google 的分布式锁服务中，只有决议确定被批准后，Learner 才能获取这个决议。

答案：对

题干：Google 没有直接实现一个包含 Paxos 算法的函数库，而是在 Paxos 算法的基础上设计了一个全新的锁服务 Chubby。

答案：对

题干：Chubby 中涉及的一致性问题都由 Paxos 解决。

答案：对

题干：锁服务的粗粒度和细粒度的区别在于持有锁的时间，细粒度的锁持有时间很长，粗粒度的锁持有时间很短。

答案：错

题干：Chubby 被划分成两部分：客户端和服务端，它之间通过 RPC 连接。

答案：对

题干：Chubby 的每个客户端都有一个 Chubby 程序库，客户端的所有应用都通过这个库中的函数来完成。

答案：对

题干：Chubby 的客户端称为 Chubby 单元，一般由五个副本组成。

答案：错

题干：Chubby 在一定的时间内，有且仅有一个主服务器。

答案：对

题干：Chubby 系统上就是一个分布式的、存储大量小文件的文件系统。

答案：对

题干：Chubby 采用的是 ACL 形式的安全保障措施。

答案：对

题干：Bigtable 中的主压缩其实是合并压缩的一种，也是定期执行。

答案：对

题干：主压缩既回收了空间，又能保证敏感数据的安全性。

答案：对

题干：Bigtable 中的一次主压缩之后，所有被压缩数据会被彻底删除。

答案：对

题干：SSTable 是 Google 为 Bigtable 设计的内部数据存储格式。

答案：对

题干：Bigtable 中的所有 SSTable 文件都存储在 GFS 上，用户可以通过键来查询相应的值。

答案：对

题干：Bigtable 中的列关键字采用“族名：限定词”的规则来定义。

答案：对

题干：Bigtable 中所有的子表地址都被记录在元数据表中。

答案：对

题干：Bigtable 中的元数据表也是由一个个元数据子表组成。

答案：对

题干：Bigtable 中的根子表其实是元数据表中一个比较特殊的子表。

答案：对

题干：Bigtable 中的根子表是元数据表的第一条记录，记录了其他元数据子表的地址。

答案：对

题干：Bigtable 中的数据都是根据行关键字进行排序的，排序使用的是词典序。

答案：对

题干：SSTable 中的数据被划分成一个个的块，每个块的大小是可以设置的。

答案：对

题干：Megastore 将数据索引分为了两大类，行关键字和列关键字。

答案：错

题干：Megastore 将数据索引分为了两大类，局部索引和全局索引。

答案：对

题干：Megastore 所面对的应用是读远多于写的。

答案：对

题干：Megastore 中的局部索引定义的作用域仅限于单个实体组。

答案：对

题干：Megastore 中的全局索引可以横跨多个实体组进行数据读取操作。

答案：对

题干：Megastore 的索引包括局部索引、全局索引、STORING 子句、可重复的索引和内联索引。

答案：对

题干：Google 的监控系统 Dapper 采用的是基于注释的监控方案。

答案：对

题干：Dapper 系统在进行二次抽样时，改动 z 值就可以改变整个系统的写入数据量。

答案：对

题干：Google 监控系统设计的两个基本要求是广泛可部署性和不间断的监控。

答案：对

题干：Dremel 可以用于定位长尾延迟，监控系统的端到端性能和关键路径上的网络延迟。

答案：错

题干：Dapper 监控数据的汇总是单独进行的，而不是伴随系统对用户的应答一起返回的。

答案：对

题干：Dapper 在信息汇总过程中，只存储 RPC 方法的名称，不存储任何 RPC 负载数据。

答案：对

题干：Dremel 和 MapReduce 并不是相互替代，而是相互补充的技术。

答案：对

题干：Dremel 可以完全替代 PowerDrill 进行海量数据的分析。

答案：错

题干：Google 要实现实时的数据交互就需要统一的存储平台和统一的数据存储

格式。

答案：对

题干：在嵌套式的数据模型中，重复深度需要考虑（ ）类型的字段，记录的是该列的值是在哪个级别上重复的。

A、Required

B、Repeated

C、Optional

D、Recorded

题干：Dremel 采用多层级服务树来执行查询操作。

答案：对

题干：PowerDrill 对数据进行分块，并对数据结构进行巧妙的设计，使得查询时可以直接略去不需要的分块。

答案：对

题干：PowerDrill 需要尽可能地将数据加载至内存，因此，它更接近内存计算。

答案：对

题干：PowerDrill 是 Dremel 的升级版，设计理念相同，可以完全替代 Dremel。

答案：错

题干：PowerDrill 主要针对 ad hoc 查询（即席查询）。

答案：对

题干：PowerDrill 使用的基数估计方法是 Hyperloglog 的变种。

答案：对

题干：AWS 的底层基础架构采用的是 Dynamo。

答案：对

题干：Dynamo 采用的是无中心的模式。

答案：对

题干：Dynamo 只支持简单的键/值（key/value）方式的数据存储，不支持复杂的查询。

答案：对

题干：Dynamo 中存储的是数据值的原始形式，即按位存储，并不解析数据的具体内容。

答案：对

题干：在 Dynamo 的改进的一致性哈希算法中使用数据分区可以减小数据分布不均衡的可能性。

答案：对

题干：在 Dynamo 的改进的一致性哈希算法中使用数据分区可以减小添加或删除设备节点时引起的数据传输。

答案：对

题干：Dynamo 的相邻虚拟节点应位于不同的地理区域。

答案：对

题干：在 Dynamo 的 Gossip 协议中，每个节点相隔固定时间，就从其他节点中任意选择一个与之通信。

答案：对

题干：在 Dynamo 的 Gossip 协议中，种子节点和所有节点都有联系，当新节点加入时通知其他节点。

答案：对

题干：在 Dynamo 的容错机制中，当节点失效时，Dynamo 会监听该节点的状态，当其恢复时，Dynamo 会重新使用该节点。

答案：对

题干：当节点发生永久性故障时，Dynamo 需要进行数据同步，此时，Merkle 哈希树可以加快检测数据传输的有效性。

答案：对

填空题示例

答案要注意区分大小写。

题干：全球企业的 IT 开销分为三部分：硬件开销、() 和管理成本。

答案：

【能耗】

题干：在中国大数据专家委员会成立大会上，委员会主任怀进鹏院士用一个公式描述了大数据与云计算的关系 $G=f(x)$ ，其中， f 代表的是 ()。

答案：

【云计算】

题干：云计算的 7 个特点包括超大规模、虚拟化、()、通用性、高可伸缩性、按需服务、极其廉价。

答案：

【高可靠性】

题干：云计算技术体系结构共 4 层，分别是 SOA 层、()、资源池层、物理资源层。

答案：

【管理中间件层】

答案：

【管理中间件层】

题干：Google 的文件系统采用的是（ ）。

答案：

【GFS】

题干：Google 的文件系统中的 Master 上，保存的三种元数据是命名空间、Chunk 与文件名的（ ），以及 Chunk 副本的位置信息。

答案：

【映射表】

题干：Google 的分布式锁服务中有 3 种节点：（ ）、Acceptors、Learners。

答案：

【Proposers】

题干：Google 的客户端和主服务器之间的通信是通过（ ）握手协议来维持的。

答案：


【KeepAlive】

题干：Bigtable 是一个分布式多维映射表，表中的数据通过一个行关键字、一个列关键字以及一个（ ）进行索引。

答案：

【时间戳】

如图所示，Bigtable 中的（ ）将所有 SSTable 一次性压缩成一个大的 SSTable 文件，该操作也是定期执行一次。



答案：

【主压缩】

题干：Bigtable 主要由三部分组成：客户端程序库、一个（ ）和多个子表服务器。

答案：

【主服务器】

题干：Megastore 提供了三种方式的读，分别是 current、() 和 inconsistent。

答案：

【snapshot】

题干：Megastore 的索引分为两大类：() 和全局索引。

答案：

【局部索引】

题干：Megastore 中共有三种副本：()、见证者副本和只读副本。

答案：

【完整副本】

题干：为了让 Dapper 在应用层透明，采用了两个方面的关键性技术：轻量级的核心功能库和 () 技术。

答案：

【二次抽样】

题干：在嵌套式的列存储中，除了记录值，还要记录结构。

答案：对

题干：011011 和 110001 的汉明距离是 ()。

答案：

【3】

程序分析题

题干：根据下图内容，请画表列出 DocId、Name.Number、Links.Backword、Name.Identity.Role、Name.Identity.Role 字段的值、重复深度和定义深度。

```
DocId: 11
Links
  Backward: 10
  Backward: 30
Name
  Identity
    Role: 'teacher'
    Jender: 'female'
  Identity
    Role: 'student'
    Number: '2023112009'
Name
  Number: '2021225883'
Name
  Identity:
    Role: 'student'
    Jender: 'male'
```

```
message Document {
  required int64 DocId;
  optional group Links {
    repeated int64 Backward; }
  repeated group Name {
    repeated group Identity {
      required string Role
      optional string Jender; }
    optional string Number; } }
```

答案：

DocId			Name.Number		
value	r	d	value	r	d
11	0	0	2023112009	0	2
			2021225883	1	2
			Null	1	1


Links.Backward			Name.Identity.Role		
value	r	d	value	r	d
10	0	2	teacher	0	2
30	1	2	student	2	2
			Null	1	1
			student	1	2

Name.Identity.Jender		
value	r	d
female	0	3
Null	2	2
Null	1	1
male	1	3

题干：请根据下列数据表 and 状态迁移图，补全表中的数据读取过程，包括当前 FSM、写入值、下一个重复深度和动作。

DocId			Links.Backward			Name.Number		
value	r	d	value	r	d	value	r	d
11	0	0	10	0	2	2023112009	0	2
			30	1	2	2021225883	1	2
						Null	1	1

Name.Identity.Role			Name.Identity.Jender		
value	r	d	value	r	d
teacher	0	2	female	0	3
student	2	2	Null	2	2
Null	1	1	Null	1	1
student	1	2	male	1	3



序号	当前FSM	写入值	下一个重复深度值	动作
1	DocId (开始)	11	0	跳转至Links.Backward
2				
3	Links. Backward	30	0	
4				
5				
6				
7				
8				
9				
10				
11				
12	Name.Identity.Role	student	0	
13				
14	Name.Number	Null	0	结束

答案：

序号	当前FSM	写入值	下一个重复深度值	动作
1	DocId (开始)	11	0	跳转至Links.Backward
2	Links.Backward	10	1	跳转至Links.Backward
3	Links. Backward	30	0	跳转至Name.Identity.Role
4	Name.Identity.Role	teacher	2	跳转至Name.Identity.Jender
5	Name.Identity.Jender	female	2	跳转至Name.Identity.Role
6	Name.Identity.Role	student	1	跳转至Name.Identity.Jender
7	Name.Identity.Jender	Null	1	跳转至Name.Number
8	Name.Number	2023112009	1	跳转至Name.Identity.Role
9	Name.Identity.Role	Null	1	跳转至Name.Identity.Jender
10	Name.Identity.Jender	Null	1	跳转至Name.Number
11	Name.Number	2021225883	1	跳转至Name.Identity.Role
12	Name.Identity.Role	student	0	跳转至Name.Identity.Jender
13	Name.Identity.Jender	male	0	跳转至Name.Number
14	Name.Number	Null	0	结束

题干：请根据以下全局字典表和 chunk 0 数据块，(1) 列出 PowerDrill 记录的数据内容；(2) 再根据数据内容“book file hello luck abandon book intelligent luck hello file”填写 chunk 1.

global-dictionary dict		chunk 0		
id	search string	chunk-dict		elements
0	abandon	id	global-id	
1	book	0	1	3
2	cheer	1	2	2
3	disk	2	4	0
4	ebay	3	5	4
5	file	4	9	0
6	hello			0
7	intelligent			2
8	luck			1
9	music			3
				4

chunk 1		
chunk-dict		elements
id	global-id	
0	0	
1	1	
2	5	
3	6	
4	7	
5	8	

答案：file ebay book music book book ebay cheer file music
02350 14532

论述题

谈谈我国云计算在某个领域的应用现状和发展潜力。

谈谈你对数据处理、数据分析的方法、技术或手段的了解。

谈谈你了解的某个云服务商，以及它能提供的服务。

谈谈你了解的云计算的前沿技术和新兴产品。